




UNIVERSITÀ DELLA CALABRIA

DIPARTIMENTO DI
INGEGNERIA INFORMATICA,
MODELLISTICA, ELETTRONICA
E SISTEMISTICA

DIMES



MONTE CARLO PER RADIOTERAPIA IN CUDA

PROF. DOMENICO TALIA

ANGELICA PORCO

ING. RICCARDO CANTINI

ANNO ACCADEMICO 2025/2026

RAPPRESENTAZIONE DEL PAZIENTE

Accuratezza e finestra terapeutica

- La dose deve distruggere le cellule tumorali TCP preservando i tessuti sani NTCP
- Scostamento critico
 - Una deviazione del 5% può alterare l'esito clinico del 10-20%
- Incertezza globale raccomandata <3,5%

Phantom Voxelizzato

- Discretizzazione 3D dell'anatomia in una griglia regolare $N \times N$
- Dimensioni tipiche
 - 2-3 mm trasversale e 2-5 mm longitudinale
- Ogni voxel è considerato un mezzo fisicamente omogeneo
- Navigazione efficiente per algoritmi Voxel Traversal

Hounsfield Units e Calibrazione

- La TAC misura il coefficiente di attenuazione μ relativo all'acqua
- Densità di massa e densità elettronica
- Indice del materiale
- Composizione elementare per sezione d'urto

INTERAZIONE FOTONE-MATERIA E PROBABILITÀ

Effetto fotoelettrico

- Il fotone viene completamente assorbito da un elettrone degli strati interni
- Meccanismo dominante a basse energie e per materiali ad alto numero atomico
- Fondamentale nelle interfacce dei tessuti ossei

Effetto Compton

- Interazione predominante nel range clinic 6-10MV
- Il fotone urta un elettrone debolmente legato cedendo parte dell'energia
- La probabilità dipende dalla densità elettronica del tessuto

Produzione di coppie

- Creazione di una coppia elettrone-positrone nel campo coulombiano del nucleo
- Richiede energie elevate e cresce con il quadrato del numero atomico
- Rilevante per energie superiori a 10MeV

Sezione d'urto

$$\tau \propto Z^n / E^3$$

Distribuzione di Klein Nishina


$$E' = E / [1 + a(1 - \cos \theta)]$$

Soglia energetica

$$E \geq 1,022 \text{ MeV}$$

$$K \propto Z^2$$

PRINCIPI E CICLO DI SIMULAZIONE MONTE CARLO



Il metodo Monte Carlo, nato con il progetto Manhattan per i neutroni, è utilizzato in fisica medica per calcolare la dose ricostruendo statisticamente il comportamento medio di molte particelle.

Non è un metodo generico adattato, ma simula il trasporto riproducendo direttamente le leggi fisiche.

Ogni particella viene trattata in modo indipendente attraverso un ciclo di eventi discreti.



NUMERI CASUALI, CONVERGENZA E VALIDAZIONE

L'errore statistico del Monte Carlo decresce lentamente seguendo la legge proporzionale a $1/\sqrt{N}$.

Per raggiungere l'accuratezza clinica necessaria, occorre simulare un elevato numero di storie, tipicamente dell'ordine di 10^8 .

Mersenne Twister:


- Standard su CPU, ha un periodo lunghissimo ma richiede uno stato interno eccessivo per l'uso su GPU.

Philox 4x32:

- Ideale per CUDA, genera numeri pseudo-casuali tramite un contatore permettendo la parallelizzazione.

A differenza del Monte Carlo generico, in radioterapia il codice deve essere validato contro dati sperimentali o codici di riferimento come DOSXYZnrc per garantire risultati clinicamente corretti.

FASI DI SVILUPPO



Per ogni versione è stata creata un'implementazione semplificata (Beer Lambert) per validare in modo isolato il campionamento del cammino libero medio.

VERSIONE CPU SEQUENZIALE (1)

1

Il sistema modella un fascio parallelo di $10 \times 10 \text{ cm}^2$ riproducendo lo spettro energetico di un LINAC Varian 2100C a 6 MV tramite i database NIST XCOM.

2

I tre processi di interazione simulati all'interno del phantom voxelizzato sono:

- Effetto fotoelettrico,
- Scattering Compton
- Produzione di coppie.

3

L'energia depositata viene calcolata voxel per voxel tramite l'approssimazione KERMA locale, trascurando il range degli elettroni secondari.

4

Questa approssimazione è fisicamente giustificata poiché il range degli elettroni Compton a queste energie è dell'ordine del centimetro, compatibile con la griglia da 3 mm.

VERSIONE CPU SEQUENZIALE (2)

La versione sequenziale, pur essendo fisicamente corretta, è limitata dai lunghi tempi di calcolo poiché non sfrutta il parallelismo hardware.

Le storie dei singoli fotoni sono intrinsecamente indipendenti

- Le storie hanno lunghezze variabili (divergenza)
- Si creano race condition quando più thread scrivono la dose sullo stesso voxel

La simulazione richiede un'elevata qualità statistica, ottenuta tramite il generatore pseudocasuale Xoshiro256, con stato inizializzato dall'algoritmo SplitMix64 per evitare artefatti statistici.

Lo scattering Compton è simulato calcolando la distribuzione angolare di Klein-Nishina tramite il metodo di rejection sampling di Kahn.

Per la gestione dei fotoni secondari si utilizza uno stack locale di dimensione fissa

L'uso dello stack locale evita costose allocazioni dinamiche di memoria (malloc e free) all'interno dei cicli critici di calcolo.

VERSIONE CPU PARALLELA

Gestione race condition

- Più thread che aggiornano simultaneamente lo stesso voxel creano race condition.
- Ogni thread accumula la dose su un array privato
- Alla fine della simulazione, i buffer locali vengono sommati all'array globale all'interno di una singola sezione critica

Bilanciamento del carico

- Le storie dei fotoni hanno lunghezze variabili
- I fotoni vengono assegnati con logica Round Robin

Qualità statistica e seed:

- Ogni thread istanzia un proprio generatore (Xoshiro256) con
 - Un seed derivato dal seed globale
 - Il proprio ID
 - La sezione aurea

VERSIONE 1 GPU

Obiettivo

Trasporre la logica sequenziale della CPU direttamente in un kernel CUDA.

Mappatura

1 Thread = 1 Fotone

Ogni thread della GPU viene associato a una particella ed è responsabile dell'intera storia del fotone.

Gestione della memoria

Copia iniziale del phantom voxelizzato come array row-major linearizzato e delle tabelle dei coefficienti di attenuazione NIST XCOM dalla memoria host alla memoria del device.

Limite

Non tiene conto della natura stocastica dell'algoritmo rispetto all'hardware parallelo.

VERSIONE 1 GPU: PROBLEMA DELLA WARP DIVERGENCE

Warp Divergence	I thread CUDA eseguono istruzioni in gruppi di 32. Poiché i fotoni subiscono interazioni casuali differenti i thread all'interno dello stesso warp deviano continuamente su rami condizionali diversi forzando l'esecuzione seriale.
Rottura della coalescenza	Il cammino tridimensionale casuale delle particelle spinge i thread a leggere voxel non contigui del phantom. Gli accessi alla memoria globale non sono coalescenti, generando continui cache miss e alta latenza.
Generazione di numeri casuali	Impossibilità di usare generatori classici ad ampio stato nei registri di un singolo thread; Necessità di algoritmi semplici.

I thread passano a un modello di consumo dinamico delle particelle.

Quando un thread esaurisce la storia del fotone assegnato, non si ferma, ma attinge immediatamente a una nuova particella da simulare calcolando dinamicamente il passo successivo.

Minimizzazione del tempo in cui i CUDA core rimangono inattivi e mitiga l'effetto della lunghezza variabile delle storie all'interno dello stesso Warp.

VERSIONE 2 GPU: DISTRIBUZIONE DINAMICA DEL CARICO DI LAVORO

Texture Memory

- Il phantom voxelizzato viene mappato e allocato all'interno della texture memory della GPU.
- Questa memoria possiede un hardware di cache dedicato ottimizzato per la località spaziale.
 - Se un fotone si sposta in un voxel adiacente, quel dato è quasi certamente già presente nella cache interna.

Uso della constant memory

- I dati fisici che vengono letti simultanea da tutti i thread vengono spostati nella memoria costante.

**VERSIONE 3:
TEXTURE MEMORY**

Il Limite dei double

Le GPU commerciali hanno unità hardware dedicate ai calcoli in doppia precisione (64-bit) ridotte rispetto a quelle in singola precisione (32-bit).



Strategia di conversione parziale

Identificazione dei moduli e delle operazioni computazionali in cui la precisione a 32-bit è sufficiente.

Conservazione precisione della matrice di dose

- L'accumulo dell'energia all'interno dei voxel del phantom mantiene la precisione a 64-bit per evitare errori sistematici di arrotondamento dovuti alla somma di milioni di contributi microscopici.

VERSIONE 3 OTTIMIZZAZIONE PRECISIONE NUMERICA

SINTESI DELLE VERSIONI GPU

Race Conditions su GPU

- Nelle regioni ad alta fluenza migliaia di thread paralleli tentano di depositare l'energia nello stesso voxel nello stesso istante.

Utilizzo di atomicAdd

- L'aggiornamento della dose deve essere protetto tramite operazioni atomiche hardware fornite da CUDA per garantire l'integrità dei dati.

Collo di bottiglia

- Le operazioni atomiche serializzano temporaneamente i thread in collisione. L'architettura moderna mitiga questo problema grazie alle cache L2 che assorbono i conflitti di scrittura.

▪ Versione 1

- Rappresenta la scrittura iniziale del codice CUDA di Monte Carlo per Radioterapia

▪ Versione 2

- Risolve lo sbilanciamento del carico tra i thread. I thread acquisiscono immediatamente il fotone successivo e rimangono attivi, eliminando l'overhead di creazione e distruzione continua.

▪ Versione 3

- Sostituzione di operazioni FP64 con FP32 riducendo la pressione computazionale.
- Integrazione della texture memory per massimizzare i cache hit di livello 1 ed evitare la latenza della memoria globale.
- Il cambio di precisione sposta una frazione microscopica di fotoni nei voxel adiacenti (998.629 voxel con dose > 0 rispetto a 998.633), con uno scostamento inferiore allo 0.0004%, fisicamente accettabile

VALIDAZIONE CODICE



Attenuazione lineare

- Regressione sul PDD con $\mu \in [0,030,0,055]cm^{-1}$



Legge di Beer Lambert

- Confronto punto per punto con tolleranza $\pm 2\%$



Sezione d'urto NIST

- Compton $> 99,9\%$ a 2MeV
- Coppie = 0



Campionamento Compton

- Coseno medio Kahn vs Klein Nishina con errore $< 5\%$



Bilancio energetico

- Energia depositata/emessa rappresenta 30%-90% del totale




Forma del PDD clinico

- Picco a 0-2cm
- Rapporti 10/max e 20/10 cm entro range



Eterogeneità acqua osso

- Dose maggiore in osso con effetto ombra $>3\%$ a 20cm



Penombra laterale

- Larghezza monotona





Gamma Index 3%/3mm

- Combina differenza di dose e distanza spaziale



Convergenza statistica

- Legge di convergenza Monte Carlo
- L'incertezza decresce come $1/\sqrt{N}$ all'aumentare delle storie simulate



ANALISI DELLE PRESTAZIONI

- Valutazione effettuata scalando il carico da 100.000 a 50.000.000 fotoni su una singola GPU Tesla T4
- Crescita lineare $O(N)$, coerente con la complessità del problema; la CPU sequenziale è l'implementazione più lenta, mentre la GPU Versione 3 è la più rapida.
- **Speedup Assoluto:** La GPU V3 raggiunge un picco di quasi 25x di accelerazione rispetto alla CPU sequenziale quando satura gli Streaming Multiprocessor.
- **Speedup Relativo:** Il salto prestazionale maggiore avviene tra la V1 e la V2 (con miglioramenti tra 1.4x e 1.9x).
- **Throughput:** A regime, la Versione 3 riesce a elaborare circa 2,2 milioni di fotoni al secondo (2.2 M fotoni/s).

PROFILING COMPUTAZIONALE E RIPARTIZIONE DEL TEMPO

Costo per singolo fotone

- L'estrazione tramite profiling rileva circa 29.113 FLOP e un trasferimento medio di 3.633 byte per particella simulata.

Ripartizione del tempo GPU

- I tempi di trasferimento dati sul bus (lettura del phantom iniziale e scrittura della dose finale) sono irrilevanti;
- il peso computazionale è quasi interamente a carico del kernel Monte Carlo.

Evoluzione della potenza di calcolo

- Si passa dai circa 2,5 GFLOPS della CPU sequenziale ai ben 64,2 GFLOPS della GPU V3.


Banda passante effettiva

- Incremento netto da circa 3,9 GB/s nella V1 fino a circa 8,0 GB/s nella V3.

Legge di Amdahl

- La simulazione finale presenta una frazione teorica di codice effettivamente parallelizzato pari a circa 0.98.

VISUALIZZAZIONE E VALIDAZIONE CLINICA




Calcolo di parametri chiave come

- Profondità di dose massima ($D_{\max} = 12.75\text{cm}$),
- Raggio terapeutico ($R_{50} = 17.45\text{cm}$)
- Penombra laterale (2.7 cm).

Curva PDD (Percent Depth Dose): Conferma la corretta zona di "build-up" superficiale generata dagli elettroni secondari e il successivo decadimento fisiologico dipendente dai materiali.

Profilo laterale: Dimostra la presenza di degradazione (penombra) senza gradini netti al bordo del fascio, validando il campionamento angolare di Klein-Nishina per la diffusione Compton.

In presenza di un inserto osseo, il simulatore riproduce correttamente l'incremento di assorbimento locale e il marcato effetto ombra nella zona d'acqua successiva.



CONCLUSIONI E SVILUPPI FUTURI

Evoluzione del progetto


- Da un codice CPU sequenziale di validazione si è arrivati a una Versione 3 GPU ottimizzata, capace di risolvere la warp divergence e superare la latenza di memoria

Validazione

- Superamento di 10 test fisici garantendo sia la convergenza statistica dell'errore, sia l'aderenza dosimetrica tramite Gamma Index rispetto allo standard clinico DOSXYZnrc.

Sviluppi futuri

- Abbandono del modello del KERMA locale per integrare il trasporto esplicito delle particelle cariche e modellare accuratamente il non equilibrio elettronico.
- Adozione di un modello di programmazione distribuita multi-nodo (MPI + CUDA) per suddividere simulazioni massive su architetture HPC.



**GRAZIE PER
L'ATTENZIONE**